

Robótica. Curso 2023/24. Trabajo final de teoría

Embodied Evolution

Amado, Ares, Mateo; Casas, Riveira, Román;

1 Resumen

Embodied Evolution (EE), o *Evolución Encarnada*, es una metodología innovadora dentro del campo de la robótica evolutiva. Esta técnica emplea una población de robots físicos que se reproducen y evolucionan autónomamente mientras están situados en su entorno de tarea.

EE facilita un proceso evolutivo totalmente distribuido entre los robots. Esto permite la adaptación autónoma y continua de los robots, integrando su interacción con el entorno físico como parte del proceso evolutivo.

Inicialmente conceptualizado como un paradigma de búsqueda paralela en colectivos de robots de pequeña escala, EE ha evolucionado para abarcar el aprendizaje distribuido de comportamientos en colectivos tipo enjambre. Entre las ventajas de EE destacan su capacidad para acelerar el proceso de evaluación y su escalabilidad, debido a su naturaleza descentralizada.

Este trabajo explora la metodología EE como una alternativa viable a las aproximaciones tradicionales de la robótica evolutiva, subrayando su potencial para fomentar desarrollos significativos en el campo de la robótica evolutiva.

2 Introducción

A medida que el campo de la robótica avanza, tanto a nivel tecnológico como en viabilidad económica, el paradigma tradicional de robots individuales operados por expertos está siendo sustituido por colectivos de robots utilizados de forma cooperativa bajo mínima supervisión humana. La evolución encarnada juega un papel crucial a la hora de posibilitar la adaptabilidad autónoma en dichos colectivos de robots.

La autonomía de estos robots ocurre en 2 niveles diferentes: por un lado, son capaces de realizar sus tareas bajo mínima supervisión externa. Por otro lado, también son capaces de, mediante mecanismos evolutivos, evaluar su propio desempeño y adaptar su comportamiento. Estas capacidades permiten desplegar estos robots en situaciones que no pueden ser fácilmente modeladas, evitando así el problema de *reality gap* (inconsistencias entre el mundo real y el simulado para el entrenamiento del robot).

Asimismo, la paralelización del proceso evolutivo debida a la descentralización de los robots permite que sea una metodología competitiva con otras técnicas de robótica evolutiva, especialmente en cuanto a velocidad de convergencia. En este documento se explorará el campo de la evolución encarnada, su definición y características, los problemas a los que se enfrenta y las posibilidades que ofrece. También se describirán casos de uso reales y su implementación.

2.1 Definición de Embodied Evolution (EE)

EE se puede definir como una metodología donde se implementan procesos evolutivos en un sistema multi-robot (2 o más robots) en un entorno físico. El sistema debe cumplir con las siguientes características:

1. Descentralizado: No existe una autoridad central que seleccione a los padres para producir descendencia o los individuos que serán reemplazados. Los robots evalúan su propio desempeño, intercambian y seleccionan material genético de forma autónoma sobre la información disponible localmente.
2. En línea: Los controladores de los robots modifican sobre la marcha, sin interrumpir sus tareas designadas: la evolución se produce durante la vida operativa de los robots y en su entorno designado. El proceso continúa después de que su despliegue.
3. Paralelo: Colaboren o no en sus tareas, la población está formada por múltiples robots que realizan sus acciones y evolucionan simultáneamente, en el mismo entorno, interactuando frecuentemente para intercambiar material genético.

2.2 Importancia y relevancia en la robótica actual

EE es un campo con amplias posibilidades de futuro. Debido a los últimos avances en inteligencia artificial, la posibilidad de llegar a desarrollar una inteligencia artificial general se toma cada vez más en serio, y una de las teorías más extendidas es la de **cognición corporizada**.

Los proponente de esta teoría argumentan que el cuerpo físico juega un papel clave en el desarrollo de la cognición, y que esta depende de las experiencias e interacciones que conlleva tener un cuerpo con capacidades senso-motoras. Varela et al. (1991), Foglia and Wilson (2013). Debido a esto, se considera que no es posible llegar a un nivel de cognición avanzado en un entorno virtual (inevitablemente menos complejo que la realidad) y que es necesario encarnar estos algoritmos para obtener buenos resultados.

Pese a esto, el interés en los últimos años sobre este campo ha decaído ligeramente, como se puede observar en el número de publicaciones que citan el artículo fundamental de esta rama (Watson et al. 2002).

Per Scopus, el número de citaciones alcanzó su máximo en 2015 (26) y está en declive desde entonces, como se puede observar en Figure 1. No se utilizó Google Scholar para extraer los datos como hizo Bredeche et al. (2018) ya que se observó que múltiples resultados eran duplicados o mal atribuidos, no obstante se puede observar una tendencia similar.




Figura 1: Citaciones por año, elaboración propia

3 Fundamentos de EE

3.1 Diferenciación entre EE y otras técnicas Robótica Evolutiva

La Evolución Encarnada incluye cualquier proceso evolutivo que tiene lugar dentro de una población de robots reales donde la evaluación, selección y reproducción se llevan a cabo por y entre los robots de forma distribuida, asíncrona y autónoma.

La robótica evolutiva incluye todos los algoritmos que utilizan algún tipo de desarrollo evolutivo, y EE es un subcategoría de ellos. (Figure 2) EE se encuentra dentro de las categorías de pruebas encarnadas (frente a pruebas simuladas, los robots existen físicamente), que se ejecutan de forma paralela y descentralizada.

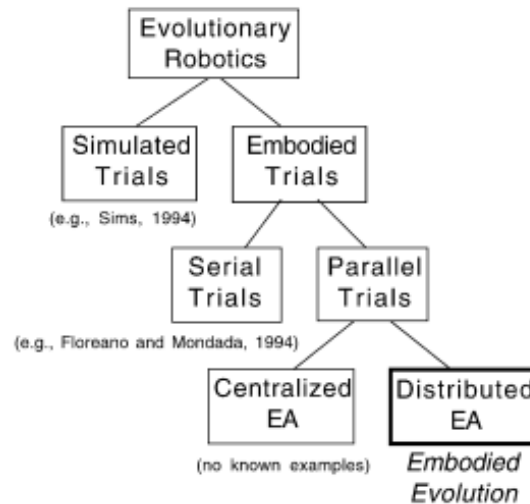


Figura 2: Clasificación de métodos de Robótica Evolutiva Watson et al. (2002)

3.2 Componentes Clave del Proceso Evolutivo en EE

El proceso evolutivo está inspirado por los principios Darwinianos de selección y reproducción del más apto. Este es común a todas las metodologías evolutivas, pero las características de EE le hacen enfrentarse a situaciones algo diferentes al resto, en concreto:

La selección usualmente se ejecuta de forma local y solo involucra a una pequeña parte de la población total. Comúnmente la probabilidad de que un robot tenga descendencia es proporcional a su capacidad en la tarea objetivo aunque pueden tenerse otros factores en cuenta (aleatoriedad, similitud de genomas, potencial...). En el caso de EE la presión selectiva no sólo es influenciada por la función objetivo especificada, sino que el entorno, y en especial los mecanismos que permiten la reproducción también ejercen presión evolutiva. Steyven et al. (2015) estudió el balance entre la presión por supervivencia y la de la tarea.

También es posible que los requisitos de la función objetiva sean opuestos a los del entorno (por ejemplo, cuando la tarea implica comportamientos arriesgados). En estos casos, la solución implica encontrar un óptimo entre completar el objetivo y mantener un entorno viable para que ocurra la evolución, lo cual crea situaciones más complejas Hart et al. (2015)

3.3 Robótica Colectiva:

La toma de decisiones descentralizada es un tema central en la investigación de la robótica colectiva. Inicialmente se intentó abordar este tipo de problemas elaborando manualmente arquitecturas de control Mataric (1994)

No obstante, para poder afrontar situaciones de mayor complejidad es necesario explorar métodos de diseño automatizados, capaces de superar las limitaciones del diseño manual y ofrecer soluciones que se

adapten a las exigencias cambiantes de los entornos operativos y capaces de ir más allá de lo que puede diseñar un humano.

Posteriormente, Bernstein et al. (2002) demostró que resolver el problema de aprendizaje multiagente más simple es imposible en tiempo polinomial: se considera un problema NEXP-complete. Es inviable obtener una solución óptima en un tiempo razonable, ya que el tiempo requerido por una Máquina de Turing No Determinista para resolverlo escala de forma exponencial, específicamente $2^{n^{O(1)}}$.

Teniendo esto en cuenta, las metodologías evolutivas parecen las más aptas para el desarrollo de estos controladores. El uso de algoritmos genéticos y otras técnicas de aprendizaje automático posibilita la emergencia de estrategias más complejas y robustas frente a cambios en el ambiente de la tarea que aquellas programadas manualmente.

EE es un área prometedora en este campo, especialmente para la investigación de como surgen este tipo de comportamientos, sin embargo el coste (tanto de dinero como de tiempo) y la complejidad de los entorno complica llevar experimentos al cabo.

Un caso especial de la robótica colectiva es el de los enjambres, consistentes en grupos de más de 100 robots, sobre los que se profundizará más adelante.

3.4 *Aprendizaje Continuo:*

Es evidente que los robots desplegados en entornos reales se beneficiarían enormemente de la capacidad de adquirir nuevas habilidades continuamente después de su implementación inicial. Nelson and Grant (2006); Thrun and Mitchell (1995).

Sin embargo, este proceso resulta particularmente complejo, especialmente en el caso de sistemas robóticos que operan de manera colectiva. Algunas soluciones deciden incluir un simulador dentro del propio robot ("simulador encarnado") O'Dowd et al. (2011), de forma que este evoluciona a la vez que los propios controladores (proceso co-evolutivo), y permite obtener un mejor modelo del mundo real.

3.5 *Escalabilidad:*

La escalabilidad constituye una característica fundamental de EE. En sistemas centralizados, estos se ve limitada por la existencia de cuellos de botella en el componente central. Por el contrario, un sistema descentralizado ofrece escalabilidad inherente, no solo en relación con la ejecución de tareas sino también en términos de su capacidad de adaptación y mejora autónoma.

4 Historia y Definición

4.1 *Historia y evolución del concepto*

Mencionado por primera vez en Jakobi et al. (1995), las principales motivaciones para la investigación en evolución encarnada eran implementar, en una población de robots reales, la evolución artificial utilizando las propiedades de la evolución natural (distribuida y autónoma); Empleándolas no sólo en el comportamiento de las tareas de los robots, sino también en su mecanismo adaptativo.

EE se plantea como solución a gran parte de los problemas que acechaban la robótica evolutiva de la época, como son la falta de fidelidad de los simuladores, la poca robustez del hardware utilizado y el prohibitivo tiempo de evaluación de los robots.

La evaluación en paralelo solventa estas problemáticas de forma nativa, ya que el despliegue de los robots en el entorno real elimina la necesidad del simulador, y la facilidad de escalar este tipo de sistema compensa la poca robustez de los robots a lo largo del tiempo mediante redundancia. Además, este escalado no provoca un aumento del tiempo de evaluación al ser totalmente paralelo y descentralizado.

En cierta forma, los costes asociados a estos problemas (desarrollo del simulador, tiempo de duración de los experimentos...) se traspasan a costes en obtener un gran número de robots y coordinarlos. La pregunta de si este traspaso es económicamente positivo es compleja de responder Bernard et al. (2016), e implica balancear variables como el número de robots óptimo, diversidad entre ellos o tiempos de convergencia.

4.2 Definición formal:

A continuación se muestra la definición del paradigma EE en pseudocódigo, introducida por (Bredeche et al. (2018)). Cada robot corre su propia instancia del algoritmo, y el proceso evolutivo emerge de las interacciones entre ellos. La modificación de los genomas es asíncrona y autónoma.

```
Inicializar robot;
for ever do
  Ciclo de Accion;
  perf ← Calcular Rendimiento;

  if Apareamiento? then
    transmitir genoma;
    g ← recibir genoma;
    guardar(g);
  end

  if Reemplazo? then
    padres ← Seleccion de padres;
    descendencia ← variacion(padres);
    activar(descendencia); % el nuevo controlador toma el control
  end
end
end
```

Profundizando un poco en cada uno de los pasos:

- **Inicializar:** Los controladores de robots suelen inicializarse de manera aleatoria, aunque también puede ser desarrollados independientemente (Hettiarachchi et al. (2006)).
- **Ciclo de Acción:** Representa el control no relacionado con el proceso evolutivo. Los detalles dependen de la implementación de cada experimento, y también ser implementado como un proceso paralelo separado.
- **Calcular Rendimiento:** Los robots miden su propio rendimiento frente a la función evolutiva. Estas mediciones se utilizan luego para evaluar y comparar genomas (como valores de aptitud en el cálculo evolutivo).
- **Apareamiento:** Este es el paso donde los robots intercambian material genético. La decisión de aparearse puede basarse en contingencias ambientales (por ejemplo, robots que se aparean siempre que están dentro del rango de comunicación), pero también pueden influir otras consideraciones (por ejemplo, la similitud genotípica). El pseudocódigo describe un intercambio simétrico de genomas (ambos con operaciones de transmisión y recepción), aunque esto puede ser asimétrico para implementaciones particulares. Schwarzer et al. (2011), Haasdijk et al. (2014a).
- **Reemplazo:** El genoma actual reemplazado por el nuevo. Este evento puede ser desencadenado por condiciones internas del robot (por ejemplo, alcanzar un nivel de rendimiento dado) o mediante interacciones con otros robots (por ejemplo, recibir material genético prometedor).
- **Selección de Padre(s):** En este proceso se selecciona qué información genética se utilizará para la creación de descendientes. El rendimiento del genoma recibido suele ser la base para la selección.
- **Variación:** Se crea un nuevo genoma aplicando los operadores de variación (mutación y cruce) sobre el(los) genoma(s) parental(es) seleccionado(s). Este es posteriormente activado para reemplazar el controlador actual.

5 Estudios de Caso

A continuación se presentará una revisión del estado del arte del campo y algunos ejemplos ilustrativos de robots que usan evolución encarnada:

5.1 Estado del Arte

Una de las principales diferenciaciones dentro de la evolución encarnada es aquellos trabajos que consideran EE como un método de búsqueda paralelo para optimizar comportamientos individuales y aquellos donde se emplea para crear comportamientos colectivos en poblaciones de robots.

Otra diferenciación clave es aquella entre poblaciones polimórficas y monomórficas, albergando las primeras múltiple grupos de individuos con un genotipo particular (normalmente asociado a un comportamiento específico). Las poblaciones monomórficas (un solo tipo de robot) tienden a lograr la cooperación más fácilmente. (ej. Schwarzer et al. (2010)) frente a las polimórficas, que requieren de condiciones más específicas para evolucionar (ej. Trueba et al. (2013))

El tipo de tarea a completar suele o bien de esquivar obstáculos o de forraje. También hay casos donde no se determina ninguna tarea y se evoluciona solamente en función a la presión ambiental. En cuanto al apareamiento, lo más común es por proximidad, pero hay casos (panmixia) donde esto no es un factor. El esquema de selección y reemplazo es otro apartado donde se pueden diferenciar distintos tipos de experimentos.

El número de robots utilizado es una de las variable más importantes, aproximadamente a partir de 2010 ha habido una serie de experimentos que emplean un gran número de robots (más de 100), desplazándose hacia una robótica más parecida a un enjambre donde la dinámica evolutiva puede ser bastante diferente Huijsman et al. (2012).

Bredeche et al. (2018) mostró como la presión ambiental por sí sola puede impulsar la evolución hacia comportamientos auto sostenibles. Los requisitos ambientales para transmitir genomas puede afectar profundamente la dinámica evolutiva, por lo que comprender estos efectos será vital para desarrollar sistemas EE eficaces y hay investigación activa en este tema.

Otras ideas recientes relacionadas incluyen el uso de enjambres de grandes cantidades de robots Asri and Zhu (2024). Esta rama de la robótica es un campo muy amplio, y EE tiene mucho potencial para ayudar a desarrollar los comportamientos complejos necesarios para el control de grandes cantidades de robots de forma descentralizada. Esta se inspira en las características algunos grupos de insectos Bayindir and Sahin (2007) para obtener robots robustos, flexibles y escalables. No obstante, habitualmente el tiempo necesario para su evolución es prohibitivo para desarrollarse en un entorno físico y se ven obligados a usar simuladores con menor fidelidad. Rubenstein et al. (2014) Otro ejemplo que requiere más investigación es el de la transferencia de conocimientos entre controladores basados en redes de neuronas artificiales, con el objetivo de acelerar el proceso de aprendizaje Kulkarni and Nair (2023)

5.2 Implementaciones

5.2.1. Algoritmos

Se han desarrollado 3 algoritmos principales en el paradigma de la evolución encarnada:

- Probabilistic Gene Transfer Algorithm (PGTA): Basado en MicrobialGA, se explicará en detalle en la siguiente sección sobre la implementación de Watson et al. (2002). T
- minimal Environment-driven Distributed Evolutionary Adaptation Algorithm (mEDEA): Utilizado por Bredeche and Montanier (2010) y Nicolas Bredeche and Winfield (2012), en este caso los robots están transmitiendo su genoma constantemente en una red local, antes de mandarlos efectúan una mutación con un operador gaussiano. Cada individuo mantiene una lista de todos los genotipos que recibió a lo largo de su vida. Hay un tiempo máximo de vida, así como un nivel de energía y de consumo. En el caso de quedarse sin energía el robot se desactiva hasta el final de esa generación. En la siguiente generación se reemplaza los desactivados por uno seleccionado aleatoriamente de

la anterior lista. La presión evolutiva ocurre a nivel poblacional, de forma que los robots que se mantengan con vida más tiempo tendrán más posibilidades de transmitir su genotipo.

■ **Asynchronous Situated Coevolution Algorithm (ASiCo):**

En este caso, la evolución está guiada por el flujo de energía en el entorno, similar a los sistemas ecológicos. Fue introducida por Prieto et al. (2009) y utilizada en Duro et al. (2011). Cada individuo lleva un genotipo de embrión además de su propio genotipo. Cuando se encuentra a otro dentro de su rango de detección, ambos comunican su aptitud (energía) y genotipo, que pueden ser aceptados o no dependiendo de la política de selección (normalmente basada en la maximización de la aptitud). Si se acepta, el genotipo entrante afectará al nuevo embrión, pero el genotipo original sigue controlando al individuo. Si un individuo se queda sin energía o supera una vida máxima predefinida, es reemplazado por su embrión después de aplicar un operador de cruce bipolar y un operador de mutación gaussiana sobre él.

5.2.2. **Watson et al. (2002) :**

Uno de los primeros experimentos en implementar la metodología en el mundo real:

Hacen uso de 8 robots, cuyo comportamiento está controlado por una arquitectura simple de red neuronal artificiales (16^4 configuraciones posibles). La tarea del robot es alcanzar una luz desde cualquier punto inicial en el mapa y una vez conseguido se restablece a un punto aleatorio del mismo. Cuentan con un comportamiento integrado de escape en caso de quedar atascados.

La única forma de que un robot modifique su controlador es mediante reproducción. Esta ocurre cuando dos robots están a muy corta distancia (forzando una especie de selección aleatoria de pareja)

La evaluación en sistemas distribuidos debe ser continua y capaz de adaptarse a las dinámicas cambiantes del entorno operativo. Esto se logra mediante la integración de sensores y algoritmos que permiten a cada robot autodiagnosticarse y ajustar su comportamiento de manera proactiva. Para evitar los problemas que conlleva el uso de baterías o cables decidieron implementar un sistema similar al de los coches de choque, de forma que obtienen energía del suelo y del techo.

La reproducción, consiste en la transferencia y modificación de los controladores entre robots, facilitando así diversificación genética. Para el proceso de selección y reemplazo desarrollaron el algoritmo PGTA (Probabilistic Gene Transfer Algorithm).

Esta consiste en una versión probabilística de MicrobialGA Harvey (2011), que minimiza la necesidad de comunicación entre agentes para efectuar la reproducción. Esta ocurre durante la tarea sin interrumpirla. Cada robot tiene un "nivel de energía" que refleja su destreza en la tarea. Cada robot hace transmitir su información genética en su rango local de forma proporcional a su nivel de energía. Cada transmisión incluye una versión mutada de un gen seleccionado al azar del genoma del robot. Si otro robot recibe esta transmisión, puede permitir que el valor del gen recibido reemplace al correspondiente en su propio genoma. El robot receptor aceptará el gen transmitido con una probabilidad inversamente proporcional a su propio nivel de energía, utilizando solo comunicación unidireccional. De esta forma se implementa un algoritmo evolutivo recombinativo proporcional a la aptitud.

Uno de los problemas que encontraron es que la recogida de datos era dificultada por la naturaleza descentralizada del algoritmo, de forma que resultaba imposible monitorizar la actividad reproductiva.

5.2.3. **Bredeche et al. (2017) :**

En este trabajo más reciente, los autores se centran en una de las problemáticas de EE, la especialización. El objetivo es obtener distintos sub-grupos de robots que evolucionan con distintas estrategias de toma de decisiones. Para ello utilizan una metodología sencilla formada por varios robots tipo Khepera en un entorno con dos tipos de recursos.

Cada robot puede recolectar energía de un tipo de recurso, y ambos recursos deben ser utilizados para que la población sobreviva. Los robots son controlados por un perceptrón simple, junto con un gen que determina su capacidad para sintetizar energía de recursos específicos.

En sus experimentos comparan los resultados obtenidos por diferentes operadores de selección, entre los que se incluyen la selección aleatoria, la selección por torneo, selección proporcional a la aptitud o

la selección basada en rangos. También cuentan con distintas configuraciones del entorno (disposición espacial de los recursos) y el número de robots de la población.

El éxito se medía en función de si desarrollaban la especialización, y podía ser completo, parcial o en el peor caso la extinción de la población. Según los resultados que obtuvieron, concluyen que los operadores de selección proporcional (aquellos que muestrean toda la población y tienen una selección sesgada por el rendimiento), son especialmente aptos para evolucionar la especialización conductual.

Matizan estas conclusiones con resultados obtenidos en experimentos previos con una metodología similar, donde encontraron que el aislamiento reproductivo y un tamaño de población grande tienen roles muy importantes en el resultado de la adaptación evolutiva.

Esto plantea la cuestión de cuál es el método más óptimo de selección, aquel basado en rango o aquel basado en aptitud. La diferencia entre ellos radica en si el peso dado a cada individuo es absoluto o relativo, y teorizan que el punto óptimo probablemente depende en gran manera de la tarea y el entorno en concreto.

6 Desafíos y Limitaciones

6.1 Retos técnicos en la implementación de EE

Uno de los objetivos de la robótica evolutiva es el desarrollo de controladores para robots de forma que ahorre tiempo y esfuerzo de los investigadores. Además, estos controladores son cada vez más complejos, hasta el punto de que en muchos casos no es posible desarrollarlos manualmente.

Matarić and Cliff (1996) desarrolló sobre varios de los retos que rodean el campo. La evolución encarnada ofrece la solución a algunos de ellos (fidelidad de los simuladores y transferencia al mundo real), pero se enfrenta a nuevos conflictos específicos a ella.

Uno de las desventajas de abandonar el simulador como entorno de entrenamiento es que uno se ve obligado a entrenar en tiempo real, lo cual puede ser prohibitivamente costoso en tiempo si no se aplica una paralelización adecuada. Es importante tener en cuenta que en casos de modelos muy complejos la simulación puede correr más lento que el tiempo real, mientras que los robots encarnados se desarrollan en el modelo más complejo posible (*reality is the best model*), nunca van a ralentizarse y tendrán fidelidad perfecta.

Otro problema nativo a la evolución encarnada es el del suministro de energía a los robots. Mantenerlos enchufados no es viable ya que las correas se enredan fácilmente, y usar estaciones de carga con baterías tampoco ya que es imposible hacerlas transparentes respecto a la tarea (le fuerza a interrumpirla por un tiempo no trivial). En la sección de casos se exploran algunas de las soluciones aportadas a esta problemática.

Las operaciones que definen el proceso evolutivo de los controladores son parte integral de su comportamiento en su entorno de tareas, por lo que su implementación es clave en el desarrollo de los robots. Gran parte de los problemas de esta metodología se encuentran en esta etapa, algunos de estos problemas son:

1. Selección local: el proceso evolutivo generalmente se implementa a través de interacciones locales entre los robots. Las parejas se seleccionan muestreando la vecindad del robot (tanto en el espacio físico como en los genomas), y se crea un nuevo individuo aplicando operadores de variación sobre los genomas muestreados. Ya que son encuentros casuales los que proporcionan el mecanismo de muestreo. Es posible que exista una discrepancia entre la función objetiva del individuo y el bienestar de la población, lo cual plantea un problema de optimización interesante.
2. Funciones objetivas versus Presión de selección: En EE el comportamiento de un individuo puede impactar directamente en la probabilidad de encuentros con otros y así influir en la selección y el éxito reproductivo. También es posible que se desarrollen estrategias específicas de apareamiento. En la evolución encarnada, el entorno, incluidos los mecanismos que permiten el apareamiento, también ejercen presión de selección. Steyven et al. (2015) investigó cómo aspectos del entorno de los robots influyen en la aparición de comportamientos particulares y el equilibrio entre la presión de supervivencia y la tarea. En casos donde una tarea implica comportamientos arriesgados o en aquellos donde la tarea requiere de recursos que también son necesarios para la supervivencia o

apareamiento, el proceso evolutivo debe establecer un equilibrio entre la optimización del objetivo(s) y el mantenimiento de un entorno viable para la evolución, lo cual es un desafío en sí mismo.

3. **Evaluación Autónoma:** Los propios robots deben medir su desempeño y compartirlo con otros robots cuando se aparean. Es necesario el desarrollo de un proceso donde los robots puedan ejecutar su evaluación independientemente de sus tareas o entorno.
4. **Objetivos múltiples:** Implementar la evolución encarnada sobre colectivos de robots con varios objetivos es considerablemente más complejo que sobre un solo objetivo. El proceso evolutivo tiende a seleccionar individuos en el frente de Pareto (existen múltiples soluciones que representan diferentes compromisos entre los objetivos. Las que están en el frente son las más óptimas) que no tienen porque ser los mejores para las tareas en cuestión.

6.2 Problemas éticos y de seguridad relacionados con EE

Uno de los principales problemas éticos asociados con EE radica en la autonomía de los robots y su capacidad para evolucionar sin supervisión humana directa. El desafío es mayor en situaciones donde los robots interactúan directamente con humanos o tienen un impacto considerable en el medio ambiente.

Además, la implementación de sistemas basados en EE podría alterar significativamente las oportunidades laborales, especialmente en industrias propensas a la automatización. A medida que los robots adquieren la capacidad de evolucionar para realizar tareas cada vez más complejas, existe la posibilidad de que la fuerza laboral humana sea desplazada, y si no se implantan medidas adecuadas las consecuencias pueden ser nefastas.

En términos de seguridad, la imprevisibilidad de cómo los robots pueden evolucionar en respuesta a su entorno y la posibilidad de comportamientos emergentes genera un riesgo que es necesario tener en cuenta.

7 Tendencias Futuras y Direcciones de Investigación

7.1 Aplicaciones

EE es útil en situaciones donde un simulador del dominio es imposible de desarrollar o donde un algoritmo centralizado es inviable.

Hay 3 campos principales que se pueden beneficiar de la aplicación de esta tecnología:

1. **Ingeniería:** Esta metodología aporta nuevas posibilidades para el despliegue de colectivos de robots, especialmente en aquellos casos donde se requiere que sean versátiles y resistentes a fallos. Esto es en parte gracias a la redundancia que implica utilizar múltiples robots y la naturaleza descentralizada del algoritmo.
2. **Biología evolutiva:** EE permite desarrollar modelos evolutivos muy precisos ya que incorpora, además de las interacciones físicas entre la población, los propios operadores evolutivos utilizados.
3. **Enfoque sintético:** La utilización de herramientas para comprender los mecanismos originalmente observados en la naturaleza puede ayudar a identificar principios generales no limitados a un sustrato biológico particular. Más allá de mejorar nuestra comprensión de estos mecanismos, también se pueden utilizar para mejorar nuestra capacidad de diseñar sistemas complejos. EE ofrece un sustrato apropiado para experimentos sobre la interacción entre robots, la resolución colectiva de problemas (donde los robots deben trabajar juntos para resolver alguna tarea) y el estudio del comportamiento grupal emergente. También es interesante el estudio de los mecanismos que descubren adaptativamente para la descomposición de problemas.

7.2 Trabajo Futuro

- **Benchmarks:** Según Prieto et al. (2015), el desarrollo de sistemas de referencia para poder evaluar las características de diferentes implementaciones de EE es clave a la hora de avanzar el campo.

Contar con benchmarks bien definidos permitirá comparar de manera objetiva el rendimiento y la eficacia de diversas estrategias y algoritmos de evolución encarnada.

- **Dinámica evolutiva:** EE genera árboles filogenéticos que pueden estudiarse desde el punto de vista de la genética poblacional o de la teoría de grafos Boumaza (2017). Profundizar en estos estudios permitirá entender mejor cómo se propagan las características a través de generaciones de robots, así como identificar patrones de evolución y adaptabilidad en entornos dinámicos.

Referencias

- Asri, E. G. and Zhu, Z. H. (2024). An introductory review of swarm technology for spacecraft on-orbit servicing. *International Journal of Mechanical System Dynamics*, 4(1):3–21.
- Bayindir, L. and Sahin, E. (2007). A review of studies in swarm robotics. *Turkish Journal of Electrical Engineering and Computer Sciences*, 15:115–147.
- Bernard, A., André, J.-B., and Bredeche, N. (2016). To cooperate or not to cooperate: why behavioural mechanisms matter. *PLoS computational biology*, 12(5):e1004886.
- Bernstein, D. S., Givan, R., Immerman, N., and Zilberstein, S. (2002). The complexity of decentralized control of markov decision processes. *Mathematics of operations research*, 27(4):819–840.
- Boumaza, A. (2017). Phylogeny of embodied evolutionary robotics. In *Proceedings of the Genetic and Evolutionary Computation Conference Companion*, GECCO '17, page 1681–1682, New York, NY, USA. Association for Computing Machinery.
- Bredeche, N., Haasdijk, E., and Prieto, A. (2018). Embodied Evolution in Collective Robotics: A Review. *Frontiers in Robotics and AI*, 5:12.
- Bredeche, N. and Montanier, J.-M. (2010). Environment-driven embodied evolution in a population of autonomous agents. In Schaefer, R., Cotta, C., Kołodziej, J., and Rudolph, G., editors, *Parallel Problem Solving from Nature, PPSN XI*, pages 290–299, Berlin, Heidelberg. Springer Berlin Heidelberg.
- Bredeche, N., Montanier, J.-M., and Carrignon, S. (2017). Benefits of proportionate selection in embodied evolution: a case study with behavioural specialization. In *Proceedings of the Genetic and Evolutionary Computation Conference Companion*, GECCO '17, page 1683–1684, New York, NY, USA. Association for Computing Machinery.
- Duro, R. J., Bellas, F., Prieto, A., and Paz-López, A. (2011). Social learning for collaboration through asico based neuroevolution. *Journal of Intelligent & Fuzzy Systems*, 22(2-3):125–139.
- Foglia, L. and Wilson, R. A. (2013). Embodied cognition. *WIREs Cognitive Science*, 4(3):319–325.
- Hart, E., Steyven, A., and Paechter, B. (2015). Improving survivability in environment-driven distributed evolutionary algorithms through explicit relative fitness and fitness proportionate communication. In *Proceedings of the 2015 Annual Conference on Genetic and Evolutionary Computation*, GECCO '15, page 169–176, New York, NY, USA. Association for Computing Machinery.
- Harvey, I. (2011). The microbial genetic algorithm. In Kampis, G., Karsai, I., and Szathmáry, E., editors, *Advances in Artificial Life. Darwin Meets von Neumann*, pages 126–133, Berlin, Heidelberg. Springer Berlin Heidelberg.
- Huijsman, R.-J., Haasdijk, E., and Eiben, A. (2012). An on-line on-board distributed algorithm for evolutionary robotics. In *Artificial Evolution: 10th International Conference, Evolution Artificielle, EA 2011, Angers, France, October 24-26, 2011, Revised Selected Papers 10*, pages 73–84. Springer.
- Jakobi, N., Husbands, P., and Harvey, I. (1995). Noise and the reality gap: The use of simulation in evolutionary robotics. In Morán, F., Moreno, A., Merelo, J. J., and Chacón, P., editors, *Advances in Artificial Life*, pages 704–720, Berlin, Heidelberg. Springer Berlin Heidelberg.
- Kulkarni, D. D. and Nair, S. B. (2023). Transfer learning for embodied neuroevolution. In *Proceedings of the Companion Conference on Genetic and Evolutionary Computation*, GECCO '23 Companion, page 2128–2135, New York, NY, USA. Association for Computing Machinery.
- Mataric, M. J. (1994). Interaction and intelligent behavior.
- Matarić, M. and Cliff, D. (1996). Challenges in evolving controllers for physical robots. *Robotics and Autonomous Systems*, 19(1):67–83. Evolutional Robots.
- Nelson, A. L. and Grant, E. (2006). Using direct competition to select for competent controllers in evolutionary robotics. *Robotics and Autonomous Systems*, 54(10):840–857.
- Nicolas Bredeche, Jean-Marc Montanier, W. L. and Winfield, A. F. (2012). Environment-driven distributed evolutionary adaptation in a population of autonomous robotic agents. *Mathematical and Computer Modelling of Dynamical Systems*, 18(1):101–129.
- O'Dowd, P., Winfield, A., and Studley, M. (2011). The distributed co-evolution of an embodied simulator and controller for swarm robot behaviours. pages 4995–5000.

- Prieto, A., Bellas, F., and Duro, R. J. (2009). Adaptively coordinating heterogeneous robot teams through asynchronous situated coevolution. In *Neural Information Processing: 16th International Conference, ICONIP 2009, Bangkok, Thailand, December 1-5, 2009, Proceedings, Part II 16*, pages 75–82. Springer.
- Prieto, A., Bellas, F., Trueba, P., and Duro, R. (2015). Towards the standardization of distributed embodied evolution. *Information Sciences*, 312:55–77.
- Rubenstein, M., Ahler, C., Hoff, N., Cabrera, A., and Nagpal, R. (2014). Kilobot: A low cost robot with scalable operations designed for collective behaviors. *Robotics and Autonomous Systems*, 62(7):966–975. Reconfigurable Modular Robotics.
- Schwarzer, C., Hösler, C., and Michiels, N. (2010). Artificial sexuality and reproduction of robot organisms. *Symbiotic Multi-Robot Organisms: Reliability, Adaptability, Evolution*, pages 384–403.
- Steyven, A., Hart, E., and Paechter, B. (2015). Understanding environmental influence in an open-ended evolutionary algorithm. In *Parallel Problem Solving from Nature – PPSN XIV; Lecture Notes in Computer Science*, Lecture Notes in Computer Science, pages 921–931. Springer.
- Thrun, S. and Mitchell, T. M. (1995). Lifelong robot learning. *Robotics and Autonomous Systems*, 15(1):25–46. The Biology and Technology of Intelligent Autonomous Agents.
- Trueba, P., Prieto, A., Bellas, F., Caamaño, P., and Duro, R. (2013). Specialization analysis of embodied evolution for robotic collective tasks. *Robotics and Autonomous Systems*, 61(7):682–693. Collective and Social Autonomous Robots.
- Varela, F. J., Thompson, E., and Rosch, E. (1991). *The Embodied Mind: Cognitive Science and Human Experience*. MIT Press, Cambridge, MA.
- Watson, R. A., Ficici, S. G., and Pollack, J. B. (2002). Embodied evolution: Distributing an evolutionary algorithm in a population of robots. *Robotics and Autonomous Systems*, 39(1):1–18.